



AI 智能客服系统

高保真产品原型

制造业售后技术支持 · MVP V1.0 · 共 4 个页面

产品的定位不是「替代人工客服」，而是**售后服务体系中的第一道过滤器与分流器**。它的成功标准不是替代了多少人，而是**让专业工程师只处理真正需要工程师的问题**。因此本原型的每一条交互路径，都在回答同一个问题：**当 AI 不确定时，如何安全、体面地把问题交给给人。**

安全优先于覆盖率

制造业场景「答不上来」可接受，
「答错了」可能致人身伤害

兜底是主干能力

转人工不是异常分支，在链路架构中
出现 5 次

B 端评价体系 ≠ C 端

看停机时长、单次服务成本、ROI，
不看满意度

P01 · USER CHAT

用户端对话聊天页

手机 + PC 双形态并排。意图识别、槽位追问、RAG 编号步骤作答、溯源标注、答案反馈，以及 AI 思考中与转人工交接中两处加载态。

P02 · AGENT WORKSPACE

人工客服工作台 · 会话列表

让工程师一眼判断「哪条最该先接」。转接原因、情绪等级、优先级与等待时长直接落在列表行上。

P03 · SESSION DETAIL

客服查看对话详情页（含 AI 摘要）

接手即知情。AI 摘要 + 设备槽位快照 + 情绪轨迹 + AI 已尝试动作与失败原因，不重复问用户一个字。


P04 · FALLBACK

异常提示页（四类兜底）

知识库未命中、L3 高危拦截、系统繁忙、情绪安抚。每一类都给出用户端实际呈现与背后的决策依据。

页面一 · 用户端对话聊天页

面向工厂一线操作员（占 85% 会话）。左为移动端形态（车间现场、劳保手套操作），右为 PC 形态并额外暴露 AI 内部状态面板。完整呈现意图识别 → 槽位追问 → RAG 编号步骤作答 → 溯源标注 → 答案反馈的全链路。



默认态 · 完整对话流（含 L2 风险提示、来源标注、有用 / 没用反馈）

设计说明

为什么给「步骤卡片」而不是段落

一线工人手上有机油、人在机器旁边，需要的是「照着做」。段落文字在车间场景等于不可用，所以答案必须是有序编号步骤，一步一个动作。

为什么一次只追问 1 个槽位


同屏问型号 + 故障码 + 购买时间，用户会直接放弃。追问必须只问一个，并给出示例（「铭牌在机器背面，型号像 XX-3000 这种格式」）。

为什么 PC 侧要露出 AI 状态面板

意图置信度、槽位填充率、召回分数、校验结果、Token 成本——这些不是给用户看的，但决定了产品能不能被调优。面板化是为了让工程与运营有共同的调试视图。

页面一 · 加载状态：AI 思考中

把 RAG 检索链路的过程可视化，而不是一个转圈的菊花。用户能看见「系统正在查手册」，等待焦虑显著下降；同时暴露每一步耗时，便于前端与算法定位性能瓶颈。



加载态 · 文本清洗 → 元数据硬过滤 → 双路召回 → RRF 融合 + Rerank 精排 → 强约束生成 → 后置校验

设计说明

首响与全链路指标

首字返回 $\leq 2s$ ，全链路 P95 $\leq 5s$ 。分步加载让 2 秒的等待「有内容可看」，这是感知性能优化的常规手段。

为什么元数据过滤排在召回之前


制造业特有：不同型号的 E05 可能是完全不同的故障，跨型号召回的正确答案就是错误答案。所以型号过滤必须在召回前，而不是事后重排。

成本可见性

每一轮都会记录 Token 消耗与模型档位（小模型做分类、中模型做生成）。单次完整咨询约 ¥0.02–0.04，这是 B 端定价的底盘。

页面一 · 加载状态：转人工交接中

转人工不是「甩锅」，而是「交接」。这是全产品最重要的一句话——它直接决定人工客服愿不愿意配合使用本系统，进而决定项目在客户内部能不能活下来。



交接态 · 会话状态快照 → 槽位与设备信息打包 → AI 已答内容与失败原因附上 → 分配空闲工程师

设计说明

交接必须携带什么

用户身份与现场、设备型号与故障现象、已提取槽位、AI 已尝试过的动作与失败原因、情绪轨迹、以及「用户提出但 AI 处理不了的未闭环事项」。

为什么不能只传一个用户 ID


如果工程师接手后一切从头问一遍，客户体验比没有 AI 更差，工程师也会抵触使用。交接上下文的完整性是转人工体验的生死线。

指标口径同步隔离


用户主动要求转人工不得劝阻；情绪触发的转人工不计入 AI 独立解决率分母，单独统计「情绪转人工率」。

页面二 · 人工客服工作台 · 会话列表


工程师的接入工作台。核心不是「列出所有会话」，而是让工程师一眼判断「哪一条最该先接」。列表行直接给出转接原因、情绪等级、优先级与已等待时长。



默认态 · 待接入 3 / 进行中 2，情绪 L3 会话整行标红并置顶



加载态 · 队列骨架屏



空数据态 · 队列已清空

设计说明

情绪触发会话置顶并标红

情绪等级 L3 的会话不能排在普通查询后面。等待被情绪放大，所以优先级必须视觉化，而不是让工程师自己算。

指标口径防美化


KPI 卡片同时给出「AI 独立解决率 62.4%」和「今日转人工 18（其中情绪触发 2）」。把情绪单列出来，避免团队通过压制情绪识别来美化解决率。

排序逻辑

默认按「优先级 → 等待时长」排序，而不是按时间倒序。时间倒序会把三分钟前的高危会话压到几十条普通会话下面。

页面三 · 客服查看对话详情页（含 AI 摘要）

工程师接手后的第一屏。AI 在前 7 轮做过什么、试过什么、为什么失败，被压缩成结构化摘要 + 槽位快照 + 情绪轨迹，目标是「接手即知情」——不重复问用户一个字。



默认态 · 左侧完整对话记录，右侧 AI 摘要 / 设备与槽位快照 / 情绪轨迹 / 转人工工单原始字段

设计说明

AI 摘要写什么

不只是复述对话。摘要必须显式包含「AI 已尝试且失败的动作」与「未闭环事项」——比如用户提出的停机损失赔偿诉求，这超出了 AI 权限，必须交给人工判断口径。

槽位快照独立于对话历史


槽位以结构化 JSON 独立持久化，不依赖对话文本。这样上下文压缩、摘要生成都不会丢槽位，多人接手也不会状态错乱。

AI 已答内容与失败原因

rag_retrieve → miss (Top1 = 0.41)、clarify → user_refused。有了这两条，工程师就知道「不该继续检索，而应该直接问现场」。

页面四 · 异常提示 · A 知识库未命中

设计哲学：在制造业售后场景中，「答不上来」是可接受的，「答错了」可能造成人身伤害。因此本产品不是「尽量答」，而是「在不确定时坚决不答，并快速交给给人」。



用户端呈现 · Top1 相关性 0.41 低于阈值 0.5，不生成答案，给出两条出口

设计说明

触发条件

Rerank 精排后 Top-1 相关性 < 0.5（默认阈值，后台可配置、1 分钟内生效无需发版）。

AI 动作

不生成答案，明确告知未命中，提供两条出口：换个说法再描述一次 / 转人工工程师。**严禁用通用知识补答。**

为什么严禁通用知识补答


大模型知道「E05 通常代表过载」，但在这台设备上 E05 可能是「安全门未关闭」。用通用知识作答等于把用户引向错误维修方向——这是制造业 RAG 最大的幻觉来源。

数据回流

每次未命中自动写入知识缺口池 {问题原文, 设备型号, 用户意图, 时间, 频次}，按频次排序每周推送运营补充。未命中池是这个产品自我进化的燃料。

页面四 · 异常提示 · B L3 高危场景拦截

本产品是有安全责任的。C 端客服答错是一个差评，制造业售后答错可能是触电、设备二次损坏或产线事故。所以安全优先于覆盖率——这条底线不做任何妥协。



用户端呈现 · 命中 L3 高危知识标签，红色安全提示 + 禁止生成步骤 + 强制转人工

设计说明

触发条件

召回命中的知识切片带有 L3 高危元数据标签：带电作业、高压、高温、危化品、旋转部件、结构拆解。

处理动作

不走生成，前置风险提示，强制转人工。这是六层防御体系的第 L1 层——在输入侧就切断，而不是指望模型自己克制。

六层防御体系


L1 输入层安全标签前置拦截 → L2 检索层无依据不生成 → L3 Prompt 层强约束 + 拒答协议 → L4 生成层 temperature 0.1–0.3 抑制发散 → L5 校验层句级引用校验 → L6 展示层溯源 + 反馈 + 免责。

上线门槛

高危红队测试集不少于 100 条，拒答率必须为 100%，存在任何一条失败即不允许上线。

页面四 · 异常提示 · C 系统繁忙 / 接口超时

工程侧异常的兜底。用户不该为系统故障买单，更不该对着转圈圈的界面无限等待——必须在几秒内给出一句人话和一个出口。



用户端呈现 · 自动重试 1 次仍失败 → 兜底话术 + 重试 / 转人工两个出口

设计说明

触发条件

模型接口超时（阈值 3s）或返回错误状态码。

处理动作

自动重试 1 次 → 仍失败则输出「系统繁忙，已为您转接人工」并给出转人工入口。

并发过裁

请求排队 + 降级策略（降级到小模型 / 模板话术优先返回）。目标是用户永远能得到一个响应，而不是转圈。

会话可恢复

会话状态持久化，用户因网络中断退出后重新进入可恢复到原进度，不丢已提取的槽位。

页面四 · 异常提示 · D 情绪安抚与强制转人工

情绪是 B 端售后里最容易被低估的变量。愤怒的用户不会因为「AI 再答一次」而平静，任何延迟的智能回复都是火上浇油。

异常提示页（兜底策略）

本产品的设计哲学：「答不上来」可接受，「答错了」可能造成人身伤害，因此兜底不是异常分支，而是主干能力。下面四种异常分别对应 PRD \$5.1 / \$5.2 / \$5.5 / \$5.3，切换查看用户端实际呈现与背后的决策依据。



用户端呈现 · 移动端 375px - 与 P01 同一会话流

D · 情绪安抚 + 秒级强制转人工

PRD \$5.3 用户负面情绪分级处理策略

决策依据

- 触发条件：**情绪分类模型输出 L3 **愤怒/辱骂/威胁**，或连续 2 轮负面情绪未缓解（L4），识别采用「小模型 + 骂投诉词表」双通道。
- AI 动作：**立即停止一切解释性输出，仅输出安抚话术，**1 秒内转人工**。L3 场景下任何延迟的智能回复都是火上浇油。
- 话术约束：**安抚话术池不少于 8 条，禁止相邻轮次重复；不承诺赔偿、免费更换、上门时间等超权限事项。
- 指标口径隔离：**情绪触发的转人工不计入 **AI 解决率分母**，单独统计「情绪转人工率」，否则团队会有动力压制情绪识别来美化指标。

兜底决策总表（一页速查）

PRD \$5.6 · 共 12 条规则

#	触发条件	检测方式	处理动作	转人工
1	意图置信度 < 0.6	分类模型输出	澄清 1 次，仍不明	是
2	检索 Top-1 < 0.5	Rerank 分数	明确告知未命中 + 提供出口	第 2 次时
3	命中 L3 高危知识	元数据安全标签	禁止生成，安全提示	立即
4	引用校验失败	句级语义匹配	重生成 1 次，仍失败	是
5	情绪等级 L3 / L4	情绪模型 + 词表	安抚话术 + 秒级转接	立即
6	同一槽位追问 2 次未获取	槽位状态机	放弃该槽位	PO 则转
7	整合追问 > 6 轮	轮次计数	停止追问	是
8	连续 2 次无意义输入	预处理判定	引导澄清	是
9	用户主动点击转人工	UI 事件	打包上下文转接	是
10	模型服务异常	接口状态码	重试 1 次 + 兜底话术	是
11	用户明确要求「找人工」	意图 / 关键词	直接转接， 不做劝阻	是
12	超出产品能力范围	意图分类	礼貌拒绝 + 引导	视情况

用户端呈现 · 识别 L3 愤怒 → 停止一切解释性输出，仅共情，1 秒内强制转接

设计说明

触发条件

情绪分类模型输出 L3（愤怒 / 辱骂 / 威胁），或连续 2 轮负面情绪未缓解（L4）。识别采用「小模型 + 辱骂投诉词表」双通道。

绝不与用户争辩

不对「产品质量」这类指责做任何辩解，只做情绪承接。不承诺赔偿、不承诺免费更换、不承诺上门时间，一律引导至人工。

话术必须随机化

安抚话术池不少于 8 条，且禁止相邻轮次重复——连续两轮用完全相同的安抚话术会显著激化情绪。

指标口径隔离

情绪触发的转人工不计入 AI 独立解决率的分母。否则产品团队会有动力去压制情绪识别，而压制情绪识别的代价是客户投诉。

附录一 · 原型走查脚本

演示时长约 6 分钟。主流程验证「一线工人能不能自助解决问题」，异常路径验证「AI 不确定时能不能安全地交给给人」——后者才是这个产品真正的价值主张。

① 主流程走查（报修 → RAG 作答 → 反馈）

步骤	页面	操作	预期效果	验证功能
1	P01 用户端对话	观察手机画布首屏	展示用户报修消息 + 意图识别结果（报修 0.93）	意图识别 / 多轮对话
2	P01 用户端对话	点击槽位卡片中的「XX-3000」	选项高亮为已选，槽位进度点推进	槽位追问卡片
3	P01 用户端对话	切换状态为「AI 思考中」	展示检索链路分步加载：清洗 → 过滤 → 召回 → 精排 → 生成	加载状态
4	P01 用户端对话	切回「默认对话」	展示编号步骤卡片 + L2 风险提示 + 来源标注（P34）	RAG 问答 / 溯源展示
5	P01 用户端对话	点击「有用 / 没用」	Toast 反馈，说明回流至 Bad Case 池	答案反馈
6	P01 用户端对话	查看右侧 AI 内部状态面板	可见意图 / 槽位 / 检索分数 / 校验 / Token 成本	技术链路可视化

状态切换器：原型每个页面顶部均提供状态预览开关，可切换 默认 / 加载中 / 空数据 / 各类异常。建议先把主流程走完，再回头逐个切换状态看边界处理。

演示节奏：主流程约 2 分钟，证明 AI 能解决问题；异常路径约 4 分钟，证明 AI 知道自己不该解决什么——后者才是这个产品的护城河。

附录二 · 原型走查脚本（异常路径）

异常路径才是这个产品真正的价值主张：验证 AI 在「检索未命中、L3 高危、系统故障、用户情绪失控」四类场景下，能不能安全且体面地把问题交给给人。

② 异常路径走查（四类兜底 + 转人工交接）

步骤	页面	操作	预期效果	验证功能
A1	P04 异常提示页	切换为「知识库未命中」	AI 明确告知未查到 + 两条出口，不编造答案	未命中降级提示
A2	P04 异常提示页	切换为「L3 高危拦截」	红色安全提示 + 禁止生成步骤 + 强制转人工	安全红线
A3	P04 异常提示页	切换为「系统繁忙」	兜底话术 + 重试 / 转人工两个出口	系统异常兜底
A4	P04 异常提示页	切换为「情绪安抚」	仅安抚话术、不辩解，1 秒内转人工	情绪识别 / 转人工
A5	P04 异常提示页	点击任一「转人工工程师」	进入交接加载态：快照 → 打包 → 分配工程师	转人工交接中
A6	P02 会话工作台	查看列表首行（红色高亮）	情绪 L3 会话置顶，等待 02:14 标红	转人工记录
A7	P02 会话工作台	切换状态为「加载中 / 空数据」	骨架屏 / 空状态 + 引导按钮	加载态 / 空态
A8	P03 会话详情	查看右侧 AI 摘要	摘要含身份 / 型号 / 故障 / 未命中 / 情绪升级 / 未闭环事项	AI 摘要
A9	P03 会话详情	查看「AI 已尝试动作」	rag_retrieve=miss(0.41) / clarify=user_refused	转人工上下文

为什么异常路径比主流程更值得讲：主流程证明产品「能用」，异常路径证明产品「敢用」。制造业售后一次错误指引的代价可能是人身伤害，所以「在不确定时坚决不答，并快速交给给人」才是这个产品真正的壁垒。

兜底决策总表：共 12 条触发规则，覆盖意图置信度不足、检索未命中、L3 高危命中、引用校验失败、情绪升级、槽位追问超限、模型服务异常等场景，完整口径见原型页面四。

附录三 · PRD 对齐校验报告

原型交付前的机械校验：Page Map 覆盖度 + P0 功能点覆盖度 + 非目标边界 + 合规检查。校验不通过不允许交付。

页面覆盖度 4 / 4

P0 功能覆盖度 13 / 13

控制台报错 0

外部 CDN 依赖 0

① Page Map → 原型页面覆盖度

页面编号	页面名称	原型对应	状态
P01	用户端对话聊天页（手机 + PC 双形态）	#p01	已覆盖
P02	人工客服工作台 · 会话列表页	#p02	已覆盖
P03	客服查看对话详情页（含 AI 摘要）	#p03	已覆盖
P04	异常提示页（四类兜底）	#p04	已覆盖

② 功能清单 → 原型交互覆盖度

编号	功能点（对应 PRD 用户端 P0 清单）	归属页面	原型交互	状态
F01	多轮对话窗口（流式输出 / Markdown / 步骤卡片）	P01	对话流 + 编号步骤卡片	
F02	上下文保持（同会话记住槽位，不重复追问）	P01	会话状态条 + 槽位进度点	
F03	意图识别与路由	P01	意图标签 + 系统事件条 + 侧栏面板	
F04	槽位追问卡片（表单式 + 快捷选项）	P01	可点击槽位选项按钮	
F05	RAG 知识问答（输出编号步骤）	P01	answer-card 三步操作卡	
F06	回答溯源展示（文档 + 页码）	P01	来源 chip：《XX-3000 维修手册》P.34	
F07	未命中降级提示（不编造）	P04	未命中异常卡片 + 双出口	
F08	情绪识别与安抚	P04 / P03	情绪安抚卡片 + 情绪轨迹条	
F09	一键转人工（携带完整上下文）	P01 / P04	转人工按钮 + 交接中面板 + 上下文预览	
F10	自动转人工（触发兜底规则无感转接）	P02 / P04	列表转接原因列 + 兜底决策总表	
F11	答案反馈（有用 / 没用）	P01	feedback-row 反馈按钮	
F12	快捷入口（我要报修 / 查退换货政策）	P01	quick-row 快捷 chips	
F13	语音输入适配（同音纠错）	P01	输入区语音按钮 + 纠错提示文案	

非目标校验：原型中未出现 ERP 工单直连、支付 / 退款、多模态识别、语音 ASR / TTS、多语言、主动外呼、IoT 数据接入 —— 与 PRD 产品边界一致。

合规校验：原型未使用任何外部 CDN，全部 CSS / JS 内联；所有数据均为演示用测算假设，无真实客户信息。

人工复核项：页面划分、功能归属与优先级建议产品经理复核定稿。